

Explicación de la Devolución del Profesor

El profesor hizo una revisión exhaustiva (y bastante estricta) de tu proyecto. Evaluó tres grandes áreas: la Arquitectura, los Principios de Diseño (DRY, KISS, YAGNI) y la metodología TDD.

Aquí te desgloso cada punto que te marcó, qué significa, su nivel de gravedad y cómo solucionarlo.

1. Problemas de Arquitectura en Capas

El profesor notó que aunque creaste las carpetas correctas (routers, service, repository), en la práctica **no estás respetando las reglas de comunicación entre ellas**.

● Gravedad Alta: "El Router es un controlador gordo"

- **¿Qué significa?** En tu archivo routers.py (el endpoint /upload), pusiste toda la lógica junta: validas el archivo, sacas el checksum, verificas duplicados, extraes el texto, llamas a la IA y finalmente llamas a la base de datos.
- **El problema:** La capa de presentación (Router) solo debería encargarse de recibir la petición HTTP y devolver una respuesta. No debe tener lógica de negocio. Además, el Router importa y llama directamente a repository.db_repo, saltándose la capa de "Service".
- **¿Cómo corregirlo?**
 1. Ve a service/pdf_service.py y crea una función "orquestadora" llamada procesar_archivo(contenido, filename, content_type).
 2. Mueve toda la lógica (checksum, pdfplumber, ollama, y guardado en BD) adentro de esa nueva función en el service.
 3. En routers.py, tu endpoint /upload simplemente debe llamar a pdf_service.procesar_archivo(...) y devolver lo que esta retorne.
 4. **Borra** las importaciones de repository dentro de routers.py. El Router solo debe hablar con el Service.

● Gravedad Media: Modelos ausentes

- **¿Qué significa?** Estás pasando diccionarios "crudos" (ej. {"filename": "...", "text": "..."}) entre tus capas.
- **¿Cómo corregirlo?** Crea una clase de Pydantic o un Dataclass llamado Documento dentro de app/models/. Usa esta clase para mover la información entre el Router, el Service y el Repositorio.

● Gravedad Baja: Documentación desalineada

- **¿Qué significa?** Tus diagramas UML (docs/clases.puml) muestran cosas que no existen en tu código, como una clase Validador.
- **¿Cómo corregirlo?** O actualizas los diagramas para que muestren la realidad, o creas ese Validador en el código para que coincida con el diagrama.

2. Violaciones a los Principios DRY, KISS, YAGNI

● Gravedad Alta: DRY (Don't Repeat Yourself)

- **Repetición de ObjectId a str:** Estás convirtiendo el ID de Mongo a String manualmente en varios lugares. **Solución:** Crea una función auxiliar en tu `repo_serializar(doc)` que haga esto una sola vez y úsala siempre que devuelvas un documento.
- **Dos fuentes de la URL de Ollama:** Tienes `OLLAMA_URL` en tu `.env` (que lee `settings.py`), pero en `pdf_service.py` haces un `os.getenv("OLLAMA_URL")` ignorando a `settings.py`. **Solución:** En tu `service`, importa `settings` y usa `settings.ollama_url`. Borra el `os.getenv`.
- **Colección duplicada:** En `database.py` definiste `collection = db["documents"]`, pero nunca la usas. En su lugar, en `db_repo.py` escribes `db["documents"].find...` repetidamente. **Solución:** Importa `collection` en tu `repo` y úsala.

● Gravedad Media: KISS (Mantenlo Simple)

- **Fallback especulativo en el Repo:** En tu función `obtener_por_id`, si falla el `ObjectId`, intentas buscarlo como un string normal. El profesor dice que eso añade complejidad innecesaria. **Solución:** Si el ID es inválido, simplemente atrapa el error y retorna `None`.

● Gravedad Baja: YAGNI (No lo vas a necesitar)

- **Librería pypdf2 sin usar:** La instalaste en `pyproject.toml` pero usas `pdfplumber`. **Solución:** Desinstálala (`uv pip uninstall pypdf2`).

3. Metodología TDD (Test Driven Development)

Este es el punto más duro de la devolución. El profesor determinó que **No aplicaste TDD**, sino que escribiste el código primero y luego le agregaste tests al final ("post-implementación"). Además, ¡los tests están rotos!

● Gravedad Alta: Tests rotos (No pasan)

- **El mensaje cambió:** Tu test espera que la respuesta sea "PDF subido, validado y guardado correctamente.", pero tu código actual devuelve "PDF subido, validado y resumido con IA exitosamente.". Al no coincidir, el test falla. **Solución:** Actualiza el texto en el test.
- **PDF Falso:** En tu test usaste un texto plano b"Texto simulado para el test de subida" fingiendo ser un PDF. Como ahora pdfplumber intenta abrirlo de verdad, se da cuenta de que no es un PDF válido y tu API explota tirando un error 500, haciendo fallar el test. **Solución:** Tienes que usar un archivo PDF real (aunque sea uno en blanco o muy chiquito) para enviarlo en el test.

● Gravedad Alta: Anti-patrones de Testing y F.I.R.S.T.

- **No son Independientes:** Tu test de "actualizar" y el de "eliminar" dependen de que el test de "subida" se ejecute primero para guardar el ID en una variable global `doc_id_prueba`. Los tests unitarios no deben depender del orden. **Solución:** Usa *fixtures* de pytest para crear un documento falso directamente en la base de datos antes de correr el test de eliminación.
- **No son Rápidos (Fast) ni aíslan (Mocks):** Tus tests están conectándose a la base de datos de MongoDB real y llamando a la IA real de Ollama cada vez que corren. Esto es lento y frágil. **Solución:** Debes usar "Mocks" (librería `unittest.mock`) para simular la respuesta de Ollama y de Mongo durante los tests, sin conectarse a ellos de verdad.
- **Falta el .env.example:** Si alguien clona tu repo de cero, no tiene el archivo `.env` porque lo ignoraste en git (lo cual está bien), pero sin él, los tests fallan. **Solución:** Crea un archivo llamado `.env.example` con valores de mentira para que sirva de plantilla.

Resumen de tu plan de acción sugerido:

1. **Arreglar los tests rotos:** (Cambiar el mensaje esperado y usar un PDF real mínimo). Es lo más urgente porque un proyecto con tests rotos reprueba al instante.
2. **Refactorizar la Arquitectura (Router -> Service):** Mover toda la lógica pesada del Router hacia el Service. Esto limpiará tu código enormemente.
3. **Limpiar el código (DRY y YAGNI):** Quitar el código duplicado en el repositorio, usar settings correctamente y desinstalar `pypdf2`.